

Primer paso para la inferencia Bayesiana: Ajustando una línea recta con Python

Luis Enrique Padilla Albores

CINVESTAV

30/07/2018

Teorema de Bayes

Teorema de Bayes:

$$P(\theta, H|D) = \frac{P(\theta, H)P(D|\theta, H)}{P(D)} \quad (1)$$

Teorema de Bayes

Teorema de Bayes:

$$P(\theta, H|D) = \frac{P(\theta, H)P(D|\theta, H)}{P(D)} \quad (1)$$

- $P(\theta, H|D)$ es el posterior.- Probabilidad de que nuestro modelo (o parámetros) sean correctos según los datos.

Teorema de Bayes

Teorema de Bayes:

$$P(\theta, H|D) = \frac{P(\theta, H)P(D|\theta, H)}{P(D)} \quad (1)$$

- ▶ $P(\theta, H|D)$ es el posterior.- Probabilidad de que nuestro modelo (o parámetros) sean correctos según los datos.
- ▶ $P(\theta, H)$ es el prior.- Mide nuestra ignorancia.

Teorema de Bayes

Teorema de Bayes:

$$P(\theta, H|D) = \frac{P(\theta, H)P(D|\theta, H)}{P(D)} \quad (1)$$

- ▶ $P(\theta, H|D)$ es el posterior.- Probabilidad de que nuestro modelo (o parámetros) sean correctos según los datos.
- ▶ $P(\theta, H)$ es el prior.- Mide nuestra ignorancia.
- ▶ $P(D|\theta, H) \equiv L(\theta, H)$ es el Likelihood.-Mide la probabilidad de que los datos se ajusten al modelo (parámetros)

Teorema de Bayes

Teorema de Bayes:

$$P(\theta, H|D) = \frac{P(\theta, H)P(D|\theta, H)}{P(D)} \quad (1)$$

- ▶ $P(\theta, H|D)$ es el posterior.- Probabilidad de que nuestro modelo (o parámetros) sean correctos según los datos.
- ▶ $P(\theta, H)$ es el prior.- Mide nuestra ignorancia.
- ▶ $P(D|\theta, H) \equiv L(\theta, H)$ es el Likelihood.-Mide la probabilidad de que los datos se ajusten al modelo (parámetros)
- ▶ $P(D)$ es la evidencia

- ▶ La evidencia se ignora para la inferencia de parámetros.

- ▶ La evidencia se ignora para la inferencia de parámetros.
- ▶ Un prior no informativo.-Distribución uniforme.

- ▶ La evidencia se ignora para la inferencia de parámetros.
- ▶ Un prior no informativo.-Distribución uniforme.
- ▶ Un Likelihood usual.-Likelihood Gaussiano.

- ▶ La evidencia se ignora para la inferencia de parámetros.
- ▶ Un prior no informativo.-Distribución uniforme.
- ▶ Un Likelihood usual.-Likelihood Gaussiano.
- ▶ Una vez que se obtiene la distribución posterior, se pueden obtener regiones de confianza de nuestros parámetros.

Método de Hiperparámetros

Método de Hiperparámetros

Cuando se tienen muchos conjuntos de datos → Método de hiperparámetros.

Método de Hiperparámetros

Cuando se tienen muchos conjuntos de datos \rightarrow Método de hiperparámetros.

- ▶ Si se tienen una colección de datos $\{D_1, \dots, D_N\}$ viniendo de diferentes fuentes $\{S_1, \dots, S_N\}$ (por ejemplo en Cosmología podrían ser supernovas, CMB, etc.), no se sabe a priori si los datos son consistentes entre ellos.

Método de Hiperparámetros

Cuando se tienen muchos conjuntos de datos → Método de hiperparámetros.

- ▶ Si se tienen una colección de datos $\{D_1, \dots, D_N\}$ viniendo de diferentes fuentes $\{S_1, \dots, S_N\}$ (por ejemplo en Cosmología podrían ser supernovas, CMB, etc.), no se sabe a priori si los datos son consistentes entre ellos.
- ▶ Una forma de obtener información sobre su consistencia es agregando un peso de probabilidad para cada conjunto de parámetros.

Método de Hiperparámetros

Cuando se tienen muchos conjuntos de datos → Método de hiperparámetros.

- ▶ Si se tienen una colección de datos $\{D_1, \dots, D_N\}$ viniendo de diferentes fuentes $\{S_1, \dots, S_N\}$ (por ejemplo en Cosmología podrían ser supernovas, CMB, etc.), no se sabe a priori si los datos son consistentes entre ellos.
- ▶ Una forma de obtener información sobre su consistencia es agregando un peso de probabilidad para cada conjunto de parámetros.
- ▶ El método puede ser encontrado en: *Lahav O., Bridle S. L., Hobson M. P., Lasenby A. N., & Sodre L., 2000, MN-RAS, 315, 45* o *Hobson M. P., Bridle S. L., & Lahav O., 2002, MNRAS, 335, 377 (HBL)*

- Se extiende el espacio de parámetros y se utiliza el teorema de Bayes

$$P(\theta, H|D) = \frac{1}{P(D)} \int P(D|\theta, \alpha, H)P(\theta, \alpha, H)d\alpha \quad (2)$$

- Se extiende el espacio de parámetros y se utiliza el teorema de Bayes

$$P(\theta, H|D) = \frac{1}{P(D)} \int P(D|\theta, \alpha, H)P(\theta, \alpha, H)d\alpha \quad (2)$$

- El nuevo Likelihood considerando hiperparámetros y partiendo de un Likelihood Gaussiano es

$$P(D; \theta, H_1) = \prod_{k=1}^N \frac{2\Gamma(\frac{n_k}{2} + 1)}{\pi^{n_k/2} |V_k|^{1/2}} (\chi_k^2 + 2)^{-(\frac{n_k}{2} + 1)} \quad (3)$$

Es posible obtener cuando un método de inferencia es mejor que el otro. Considerando la razón

$$K = \frac{P(D|H_1)}{P(D|H_0)} \quad (4)$$

Es posible obtener cuando un método de inferencia es mejor que el otro. Considerando la razón

$$K = \frac{P(D|H_1)}{P(D|H_0)} \quad (4)$$

Se obtiene de forma explícita

$$K = \prod_{k=1}^N \frac{2^{n_k/2+1} \Gamma(n_k/2 + 1)}{\chi_k^2 + 2} e^{-\chi_k^2/2}. \quad (5)$$

Es posible obtener cuando un método de inferencia es mejor que el otro. Considerando la razón

$$K = \frac{P(D|H_1)}{P(D|H_0)} \quad (4)$$

Se obtiene de forma explícita

$$K = \prod_{k=1}^N \frac{2^{n_k/2+1} \Gamma(n_k/2 + 1)}{\chi_k^2 + 2} e^{-\chi_k^2/2}. \quad (5)$$

K value	Strenght of evidence
< 1	Negative (supporting H_0)
1 to 3	Weak
3 to 10	Substantial
10 to 30	Strong
30 to 100	Very Strong
> 100	Decisive

Table 1: Criteria for the ratio between two Bayesian evidence, taken from [?].

Herramientas numéricas

- ▶ Se utiliza un MCMC para el cálculo del posterior.
- ▶ Se escoge un criterio de aceptación (o no) del paso.-Metropolis Hasting
- ▶ Es necesario un criterio de convergencia.- Gelman-Rubin
- ▶ Dibujar regiones de confianza para los parámetros que mejor se ajustan a los datos.
- ▶ Usaremos PyMC3 para resolver nuestro primer ejemplo
- ▶ PyMC3 (<https://docs.pymc.io/>) es un paquete de Python que nos permite hacer inferencias bayesianas a partir de métodos avanzados de MCMC.